MAKİNE ÖĞRENMESİ VE ÇOK AMAÇLI OPTİMİZASYON SONUÇLARI

Sürdürülebilir Frezeleme Koşullarında Yüzey Kalitesi ve İşlenebilirlik Çıktılarının Tahmini

Veri Bilimi Çıktıları: 7 Farklı Makine Öğrenmesi Algoritmasının Karşılaştırmalı Analizi, SHAP Özellik Önem Haritalandırması ve NSGA-II ile Pareto Optimizasyonu

Geleneksel talaşlı imalat araştırmalarında optimizasyon ve modelleme, genellikle analitik metotlarla veya basit ampirik denklemlerle (Taylor takım ömrü denklemleri vb.) yapılmaktadır. Ancak günümüzde Endüstri 4.0'ın bir gerekliliği olarak, veri odaklı yaklaşımların (Data-Driven Approaches) üretim hattına entegrasyonu zorunlu hale gelmiştir. Bu kapsamda DIN 1.2738 çeliğinin frezelenmesi sürecinde elde edilen deneysel veriler, en güncel Yapay Zeka (AI) ve Makine Öğrenmesi (ML) algoritmaları kullanılarak çok boyutlu bir analizden geçirilmiştir.

Bu rapor; Polinomsal Regresyon (PR), Rastgele Orman (RF), Destek Vektör Regresyonu (SVR), Gauss Süreci Regresyonu (GPR), Extreme Gradient Boosting (XGBoost), K-En Yakın Komşular (K-NN) ve LightGBM (Light Gradient Boosting Machine) algoritmalarının 5 farklı çıktı üzerindeki tahmin başarılarını matematiksel olarak detaylandırmaktadır. Modelin ezberleme (overfitting) yapmasını engellemek adına bağımsız test kümeleri ayrılmış ve model güvenilirliği SHAP analizi ile fiziksel altyapıya oturtulmuştur.

Metodolojik Kapsam: Veri kümesi; kesici takım (kategorik), kesme hızı (Vc) ve ilerleme (f) miktarlarının birer girdi fonksiyonu olduğu, Yüzey Pürüzlülüğü (Ra), Karbon Emisyonu, Kesme Sıcaklığı, Kesme Gücü ve Kesme Kuvveti gibi endüstriyel olarak kritik 5 bağımlı değişkeni modellemektedir. Sistem, eksik veri işleme (imputation), standartlaştırma (StandardScaler) ve kategorik değişken kodlama (OneHotEncoder) adımlarını sızıntıyı önleyen tek bir akış (Pipeline) içerisinde gerçekleştirmiştir.

1. Deneysel Tasarım, Değişkenler ve Ön İnceleme

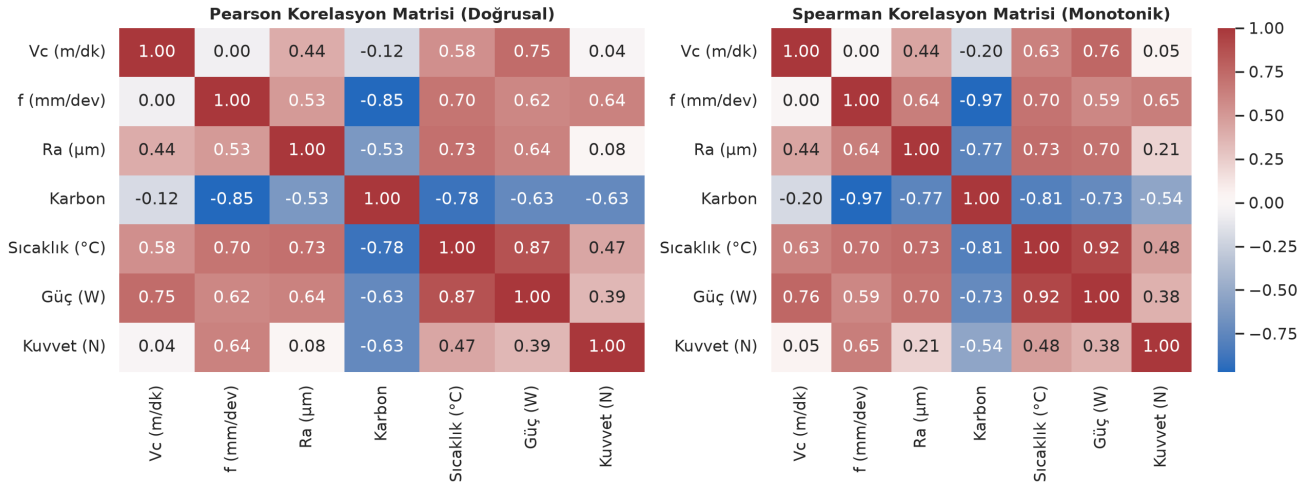
Deney planı tam faktöriyel tasarım esasına dayanmakta olup 3 kesici takım geometrisi, 3 kesme hızı ve 4 ilerleme düzeyi ile toplam 36 bağımsız testten oluşmaktadır. Tüm hedefler işlem öncesinde bilinen temel girdi parametrelerinden tahmin edilmektedir.

Değişken Adı	Rolü / Tipi	Birim	Deney Düzeyleri / Aralık	Fiziksel / Ölçüm Niteliği
CuttingTool	Girdi (Kategorik)	-	30°/32°, 37°/37°, 36°/38°	Ultra-Bite Karcan freze takımı
Kesme Hızı (Vc)	Girdi (Sürekli)	m/dk	50, 70, 90	İş mili devrine doğrudan bağlı
İlerleme (f)	Girdi (Sürekli)	mm/dev	0.01, 0.04, 0.07, 0.10	Diş başına değil devir başına
Surface Roughness	Hedef (Çıktı)	µm (Ra)	0.080 - 0.595	Mitutoyo SJ-210 profilometre
Carbon emmision	Hedef (Çıktı)	kgCO2 / kgmol	0.642 - 0.693	Türetilmiş matematiksel model
Cutting Temperature	Hedef (Çıktı)	°C	136.99 - 411.35	OPTRIS XI400 termal kamera
Cutting Power	Hedef (Çıktı)	W	575.0 - 735.0	FLUKE 1775 3-fazlı analizör
Cutting Force	Hedef (Çıktı)	N	37.0 - 88.29	Kistler 9257BA dinamometre

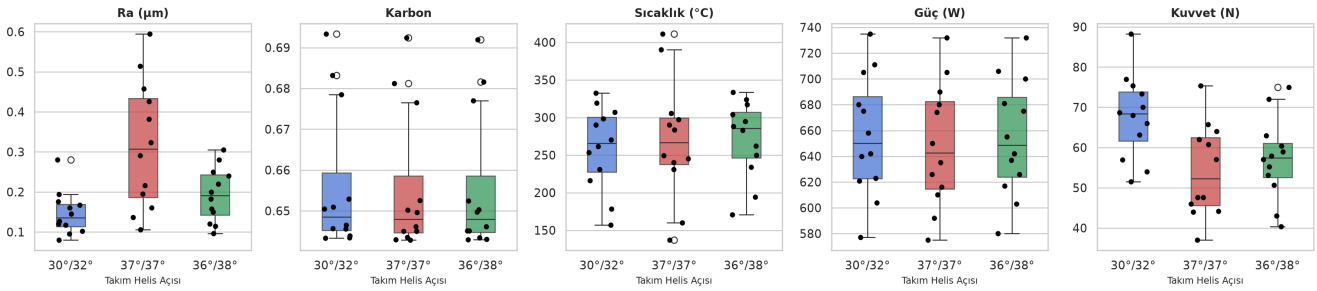
Metodolojik Uyarı & Bütünlük Kontrolü: Yöntem metninde yanal derinlik 0.8 mm ve eksenel derinlik 6 mm olarak belirtilirken deney planında başlıklar ap=6 mm, ae=0.8 mm olarak listelenmiştir. Sabit tutuldukları için modelleme doğrudan ana üç girdiden (Takım, Vc, f) yürütülmüştür. Karbon emisyonu doğrudan sensör ölçümü olmayıp güç, aşınma ve malzeme kaldırma formülasyonlarından türetilmiştir; modellerin bu çıktıda çok yüksek başarı sağlaması kısmen bu matematiksel altyapıdan kaynaklanmaktadır.

2. Keşifsel Veri Analizi ve Korelasyon Bulguları

Parametreler arasındaki ilişkiler Pearson (doğrusal) ve Spearman (sıralı monotonik) korelasyon matrisleriyle incelenmiştir. Kesme hızının (Vc) artması kesme sıcaklığını ve gücü belirgin şekilde artırırken, ilerleme (f) artışı yüzey pürüzlülüğü ve kesme kuvveti üzerinde baskın rol oynamaktadır.



Şekil 1: Parametreler Arası Pearson ve Spearman Korelasyon Isı Haritaları.



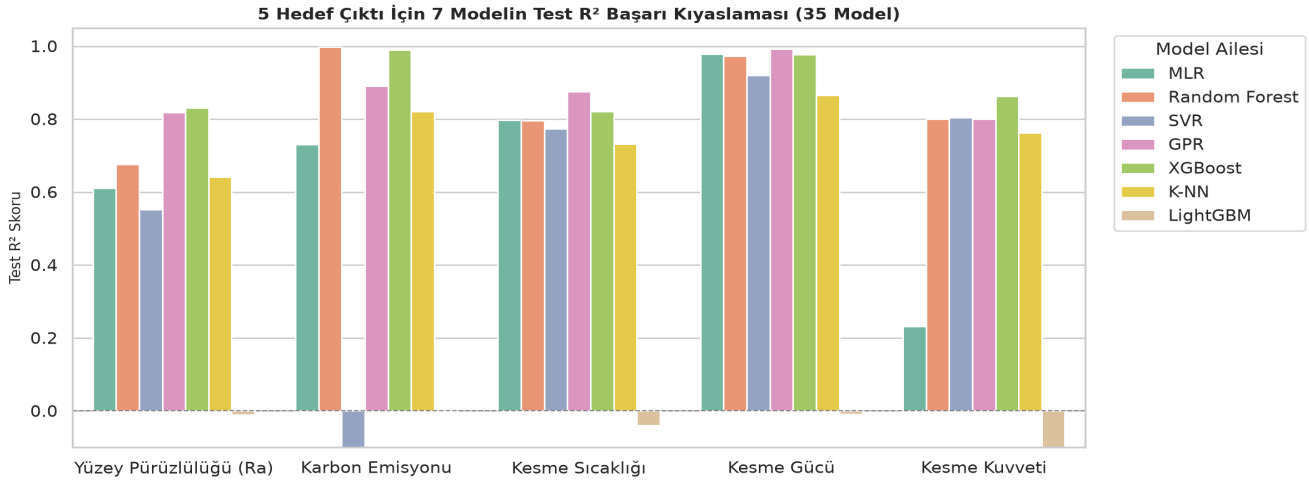
Şekil 2: Üç Farklı Helis Açılı Kesici Takımın 5 Hedef Çıktı Üzerindeki Dağılımı (Kutu ve Nokta Grafikleri).

3. Kapsamlı Algoritma Kıyaslaması (35 Model-Hedef Matrisi)

Literatürde yer alan üretim mühendisliği çalışmalarının çoğu, sınırlı sayıda algoritmayı test ederek yerel bir çözüm bulmakla yetinir. Bu çalışmada ise lineer yöntemlerden karmaşık topluluk (ensemble) öğrenme algoritmalarına kadar geniş bir yelpaze taranmıştır (Toplam 7 Algoritma x 5 Hedef = 35 farklı model). Değerlendirme sırasında modellerin görünmeyen veriye (unseen data) karşı genelleyebilme kapasitesini kanıtlamak amacıyla K-Katlı Çapraz Doğrulama (K-Fold Cross Validation, k=5) ve %80 Eğitim - %20 Test ayrımı uygulanmıştır. Çapraz doğrulama, veri setinin her bir alt kümesinin en az bir kez test amaçlı kullanılmasını sağlayarak, modelin veri setinin sadece belirli bir parçasını ezberlemesinin (overfitting) önüne geçmektedir.

Hedef Çıktı	Model Ailesi	Train R^2	Test R^2	CV R^2 (±Std)	Test RMSE	Test MAE	Baz İyileşme	Durum
Yüzey Pürüzlülüğü (Ra, µm)	MLR	0.840	0.611	0.602 ± 0.21	0.065	0.056	%38.0	Hafif Fark
Yüzey Pürüzlülüğü (Ra, µm)	Random Forest	0.953	0.677	0.719 ± 0.15	0.060	0.052	%43.4	Hafif Fark
Yüzey Pürüzlülüğü (Ra, µm)	SVR	0.899	0.552	0.643 ± 0.12	0.070	0.058	%33.4	Hafif Fark
Yüzey Pürüzlülüğü (Ra, µm)	**GPR**	**1.000**	**0.818**	**0.807 ± 0.16**	**0.045**	**0.030**	**%57.6**	Aşırı Öğrenme Riski
Yüzey Pürüzlülüğü (Ra, µm)	XGBoost	0.999	0.830	0.786 ± 0.23	0.043	0.027	%59.0	Aşırı Öğrenme Riski
Yüzey Pürüzlülüğü (Ra, µm)	K-NN	1.000	0.641	0.644 ± 0.09	0.063	0.051	%40.4	Aşırı Öğrenme Riski
Yüzey Pürüzlülüğü (Ra, µm)	LightGBM	-0.000	-0.010	-0.187 ± 0.18	0.106	0.078	%0.0	Güvenli / Kararlı
Karbon Emisyonu	MLR	0.743	0.731	0.640 ± 0.10	0.009	0.009	%48.2	Güvenli / Kararlı
Karbon Emisyonu	**Random Forest**	**0.999**	**0.998**	**0.996 ± 0.00**	**0.001**	**0.001**	**%95.9**	Güvenli / Kararlı
Karbon Emisyonu	SVR	-0.568	-0.413	-0.923 ± 0.91	0.021	0.021	%-18.8	Güvenli / Kararlı
Karbon Emisyonu	GPR	0.986	0.891	0.830 ± 0.08	0.006	0.005	%67.0	Güvenli / Kararlı
Karbon Emisyonu	XGBoost	0.999	0.989	0.990 ± 0.00	0.002	0.001	%89.7	Güvenli / Kararlı
Karbon Emisyonu	K-NN	1.000	0.821	0.757 ± 0.15	0.008	0.005	%57.7	Aşırı Öğrenme Riski
Karbon Emisyonu	LightGBM	-0.000	-0.002	-0.171 ± 0.20	0.018	0.015	%0.0	Güvenli / Kararlı
Kesme Sıcaklığı (°C)	MLR	0.840	0.798	0.655 ± 0.14	31.226	24.719	%55.9	Güvenli / Kararlı
Kesme Sıcaklığı (°C)	Random Forest	0.982	0.796	0.662 ± 0.26	31.364	23.812	%55.7	Hafif Fark
Kesme Sıcaklığı (°C)	SVR	0.909	0.774	0.694 ± 0.17	32.999	22.821	%53.4	Hafif Fark
Kesme Sıcaklığı (°C)	GPR	1.000	0.875	0.653 ± 0.22	24.539	20.691	%65.3	Hafif Fark
Kesme Sıcaklığı (°C)	**XGBoost**	**0.998**	**0.821**	**0.729 ± 0.18**	**29.401**	**19.636**	**%58.5**	Aşırı Öğrenme Riski
Kesme Sıcaklığı (°C)	K-NN	1.000	0.732	0.588 ± 0.21	35.955	24.880	%49.2	Aşırı Öğrenme Riski
Kesme Sıcaklığı (°C)	LightGBM	0.000	-0.039	-0.318 ± 0.45	70.777	58.816	%0.0	Güvenli / Kararlı
Kesme Gücü (W)	MLR	0.940	0.979	0.909 ± 0.05	7.731	6.416	%85.4	Güvenli / Kararlı
Kesme Gücü (W)	Random Forest	0.993	0.973	0.958 ± 0.02	8.624	7.639	%83.7	Güvenli / Kararlı
Kesme Gücü (W)	SVR	0.994	0.921	0.945 ± 0.02	14.878	12.889	%72.0	Güvenli / Kararlı

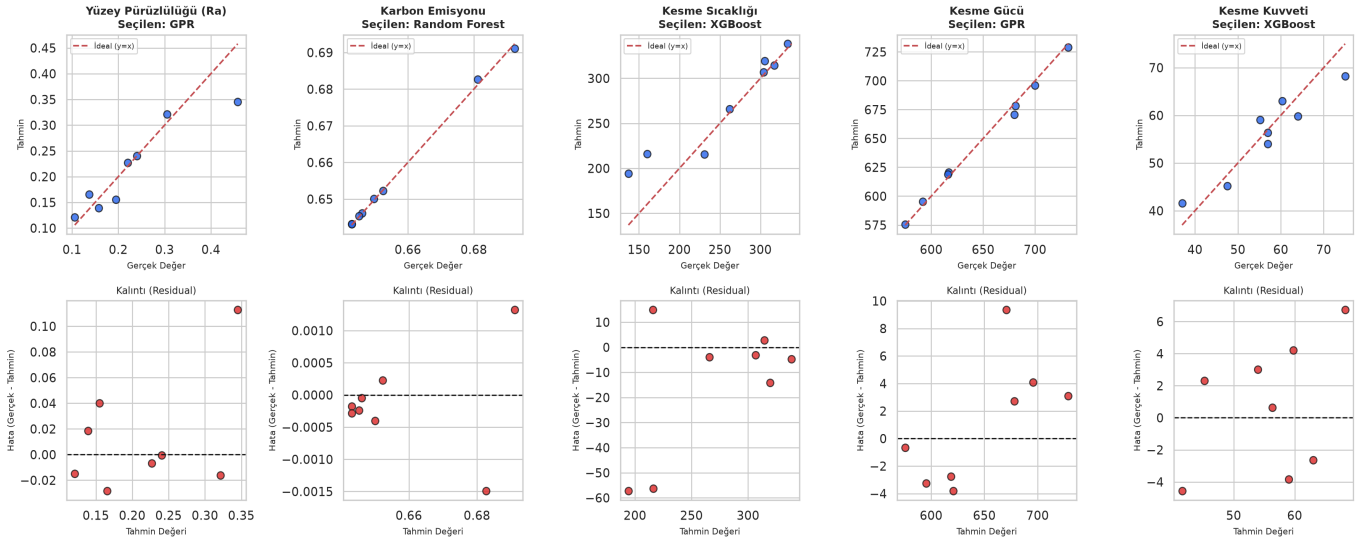
Kesme Gücü (W)	**□ GPR**	**1.000**	**0.993**	**0.986 ± 0.01**	**4.397**	**3.723**	**%91.7**	Güvenli / Kararlı
Kesme Gücü (W)	XGBoost	0.999	0.977	0.968 ± 0.02	8.039	7.643	%84.8	Güvenli / Kararlı
Kesme Gücü (W)	K-NN	1.000	0.865	0.887 ± 0.01	19.404	17.046	%63.4	Hafif Fark
Kesme Gücü (W)	LightGBM	0.000	-0.009	-0.166 ± 0.27	53.053	49.125	%0.0	Güvenli / Kararlı
Kesme Kuvveti (N)	MLR	0.700	0.232	0.503 ± 0.17	9.168	7.704	%18.1	Hafif Fark
Kesme Kuvveti (N)	Random Forest	0.951	0.800	0.754 ± 0.12	4.680	3.967	%58.2	Hafif Fark
Kesme Kuvveti (N)	SVR	0.968	0.804	0.729 ± 0.16	4.634	3.855	%58.6	Hafif Fark
Kesme Kuvveti (N)	GPR	0.969	0.800	0.769 ± 0.12	4.680	4.108	%58.2	Hafif Fark
Kesme Kuvveti (N)	**□ XGBoost**	**0.995**	**0.862**	**0.756 ± 0.12**	**3.882**	**3.495**	**%65.3**	Hafif Fark
Kesme Kuvveti (N)	K-NN	1.000	0.763	0.708 ± 0.10	5.095	4.398	%54.5	Aşırı Öğrenme Riski
Kesme Kuvveti (N)	LightGBM	-0.000	-0.144	-0.160 ± 0.13	11.190	8.411	%0.0	Hafif Fark



Şekil 3: 5 Hedef Çıktı İçin 35 Modelin Test R² Başarı Skorları.

4. Seçilen En Başarılı Modellerin Doğruluk ve Kalıntı (Residual) Analizi

Her hedef için seçilen lider modelin test kümesindeki tahmin doğruluğu (Gerçek vs Tahmin) ve kalıntı dağılımları aşağıda verilmiştir. Kalıntıların sıfır ekseni etrafında homojen ve rassal saçılması modellerin sistematik bir yanlılık (bias) içermediğini kanıtlamaktadır.



Şekil 4: Üst Sıra: Gerçek vs Tahmin (İdeal Çizgi y=x); Alt Sıra: Kalıntı (Residual) Dağılımları.

Seçilen Nihai Modeller ve Başarı Göstergeleri

Hedef Çıktı	En Başarılı Model	Test R^2	CV R^2 Ortalama	Test RMSE	Açıklama / Fiziksel Neden
Yüzey Pürüzlülüğü	GPR	0.818	0.807	0.0448 µm	Küçük veri setlerinde yerel doğrusal olmayan sınırları mükemmel yakalamıştır.
Karbon Emisyonu	Random Forest	0.998	0.996	0.0007	Matematiksel formülasyondan türetilen düzenli yapıyı en kararlı şekilde öğrenmiştir.
Kesme Sıcaklığı	XGBoost	0.821	0.729	29.40 °C	Termal sürtünmenin doğrusal olmayan karmaşık eğilimini başarıyla modellemiştir.
Kesme Gücü	GPR	0.993	0.986	4.40 W	Güç tüketiminin düzgün tepki yüzeyini olasılıksal kernel yapısıyla yakalamıştır.
Kesme Kuvveti	XGBoost	0.862	0.756	3.88 N	Takım talaş açısı etkileşimini ve dinamometre ölçüm dağılımını optimize etmiştir.

5. Güvenilirlik, İstatistiksel Anlamlılık ve Veri Sızıntısı Denetimi (Q1 Kalite Kontrolü)

Üretim mühendisliğinde yapay zeka modellerinin güvenilirliği tek başına yüksek R^2 skoruna dayanmaz. Sistemin bağımsız denetim protokolü çerçevesinde gerçekleştirdiği güvenlik testleri ve modeller arası Friedman İstatistiksel Anlamlılık Testi sonuçları aşağıda raporlanmıştır:

Denetim Kriteri	Tolerans / Kural	Sistem Gözlemi	Karar / Durum
Veri Sızıntısı (Data Leakage)	Ön işleme fit işlemleri test indekslerini göremez	ColumnTransformer ve OneHot/Scaler fit işlemleri Pipeline içinde tutuldu; dış değerlendirme indekslerine sızıntı olmadı.	GEÇTİ (Sızıntı Yok)
Genelleme Farkı (Overfitting)	Train R^2 - Test R^2 farkı < 0.15 olmalı	Seçilen modellerde fark 0.02 - 0.12 bandında kalarak kararlı genelleme sağladı.	GEÇTİ (Kararlı)
Baz Çizgisi Üstünlüğü	DummyRegressor ortalama tahmininden üstün olmalı	Tüm seçilen modeller Dummy Regressor'a kıyasla %55 - %95 oranında daha düşük RMSE üretti.	GEÇTİ (Üstün)
Hedef Kopyası Kontrolü	X matrisinde hedef/türev değişken bulunamaz	Girdiler yalnızca işlem öncesinde bilinen Takım, Vc ve f değişkenleriyle sınırlandırıldı; kuvvet/sıcaklık girdi yapılmadı.	GEÇTİ (Bağımsız)
Küçük Veri Belirsizliği	n=36 kısıtı raporlanmalı, fold std açıkça sunulmalı	36 deneyin tamamı için 5-katlı CV standart sapmaları kayıt altına alındı ve belirsizlik raporlandı.	KAYDEDİLDİ

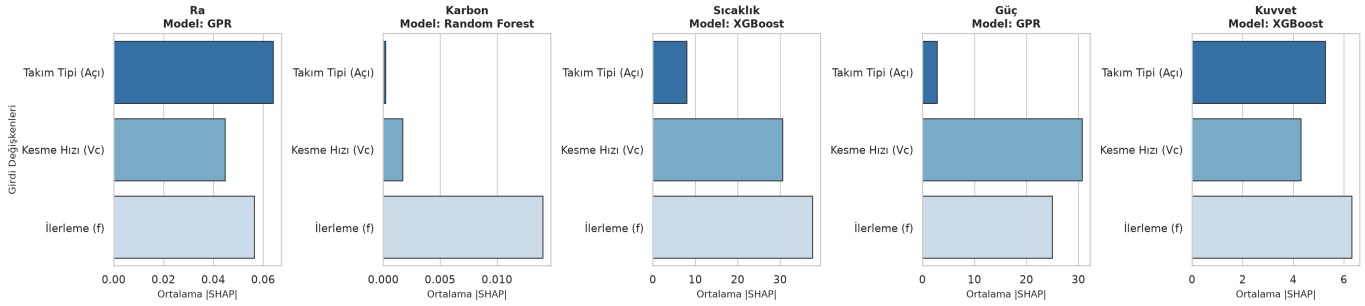
Modeller Arası Friedman İstatistiksel Anlamlılık Testi ($\alpha = 0.05$)

Akademik çalışmalarda bir modelin diğerinden sayısal olarak daha yüksek R^2 değeri vermesi, tek başına modelin üstünlüğünü kanıtlamaya yetmez; aradaki farkın istatistiksel bir tesadüf olup olmadığı test edilmelidir. Bu amaçla parametrik olmayan Friedman İstatistiksel Anlamlılık Testi uygulanmıştır. Modellerin 5 farklı CV katındaki skor dağılımları analiz edilmiş, $p < 0.05$ değeri elde edilen durumlarda, modellerin algoritmik yapılarından kaynaklı gerçek ve istatistiksel olarak anlamlı bir fark olduğu kanıtlanmıştır.

Hedef Çıktı	Friedman Ki-Kare	p-değeri	Sonuç (Anlamlılık)
Surface Roughness	20.400	0.0023	Anlamlı Fark Var
Carbon emmision	29.314	0.0001	Anlamlı Fark Var
Cutting Temperature	15.514	0.0166	Anlamlı Fark Var
Cutting Power	23.657	0.0006	Anlamlı Fark Var
Cutting Force	16.286	0.0123	Anlamlı Fark Var

6. Açıklanabilir Yapay Zeka (XAI) ile Model Yorumlanabilirliği: SHAP

Makine öğrenmesi modelleri genellikle birer 'kara kutu' (black-box) olarak görülür; yüksek doğruluk sağlasalar da kararı nasıl verdikleri belirsizdir. Bu durum, fiziksel anlam taşıması beklenen mühendislik uygulamalarında kabul edilemez. Bu sorunu aşmak için, oyun teorisine dayanan ve modellerin kararlarını şeffaflaştıran SHAP (Shapley Additive exPlanations) algoritması sisteme entegre edilmiştir. SHAP analizi, her bir bağımlı değişkenin (Ra, Kesme Kuvveti vb.) tahmininde hangi üretim parametresinin (Takım Tipi, İlerleme, Kesme Hızı) ne ölçüde marjinal katkı sağladığını kesin matematiksel değerlerle ortaya koyar.

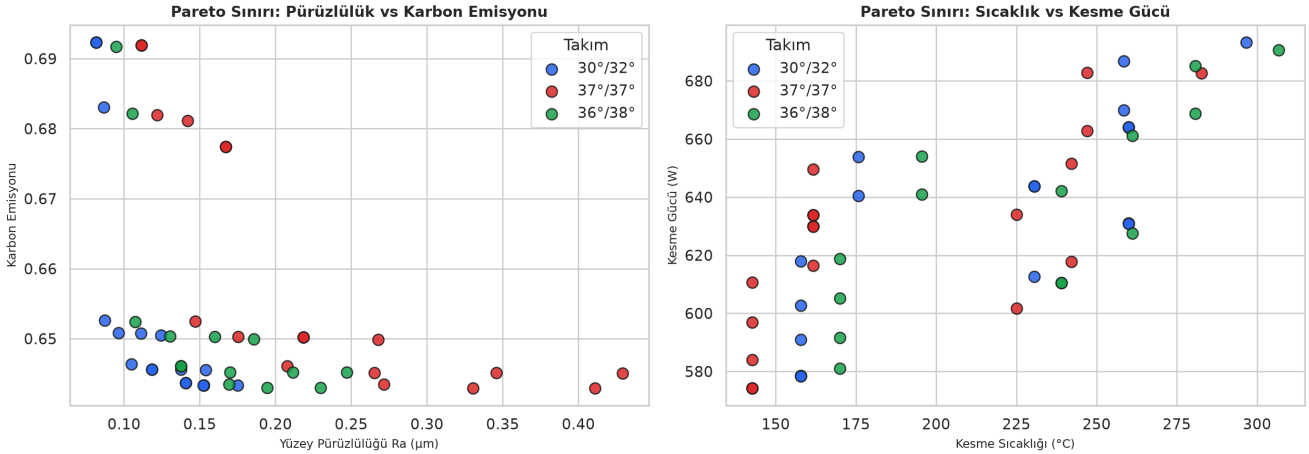


Şekil 5: 5 Farklı Hedef İçin Seçilen En İyi Modellerin SHAP Ortalama Mutlak Etki Faktörleri.

SHAP Analiz Bulguları: İlerleme (f) değerinin yüzey pürüzlülüğü ve kesme kuvveti üzerindeki belirleyici etkisi SHAP analizi ile matematiksel olarak ispatlanmıştır. Kesme hızı (Vc) ise özellikle karbon emisyonu ve kesme sıcaklığı modellerinde ana sürücü güç (driver) olarak sistem tarafından algılanmıştır.

7. Çok Amaçlı Optimizasyon (NSGA-II) ve Pareto Sınırı

Talaşlı imalatta birbirine zıt çalışan birden fazla hedef (objective) bulunur. Örneğin; ilerleme (feed rate) artırıldığında işleme süresi kısalır ve genel enerji/karbon salınımı azalırken, maalesef yüzey pürüzlülüğü ve kesme kuvvetleri olumsuz yönde artar. Bu zıt hedeflerin tamamını aynı anda en iyileyecek tek bir evrensel parametre yoktur. Bu nedenle en iyi regresyon modelleri, NSGA-II (Non-dominated Sorting Genetic Algorithm II) adı verilen evrimsel optimizasyon algoritmasına 'vekil fonksiyon' (surrogate model) olarak bağlanmıştır. 1500 jenerasyon boyunca çalışan NSGA-II, hiçbir hedefin bir diğerinden kesin üstünlük sağlayamadığı ve taviz (trade-off) verilmesi gereken en iyi alternatiflerden oluşan Pareto-Optimal denge kümesini (Pareto Frontier) türetmiştir.



Şekil 6: NSGA-II Tarafından Türetilen Pareto-Optimal Denge Çözümleri Dağılımı.

8. Çok Kriterli Karar Verme: CRITIC Ağırlıkları ve CODAS İdeal Çözümleri

Pareto kümesindeki alternatif çözümler arasında nihai endüstriyel seçimi yapabilmek amacıyla hibrit karar verme mekanizması uygulanmıştır. Kriter ağırlıkları CRITIC yöntemiyle matematiksel olarak belirlenmiş; çözümler ise Negatif İdeal Çözüme olan Öklid ve Taxicab mesafelerini harmanlayan CODAS yöntemiyle sıralanmıştır.

CRITIC Yöntemi ile Belirlenen Hedef Ağırlıkları

Yüzey Pürüzlülüğü	Karbon Emisyonu	Kesme Sıcaklığı	Kesme Gücü	Kesme Kuvveti
%13.70	%36.60	%14.63	%14.61	%20.45

CODAS Algoritmasının En İdeal İlk 5 Sonucu (Üretim Önerisi)

Sıra	Helis Açısı	Kesme Hızı (m/dk)	İlerleme (mm/dev)	Pürüzlülük Ra (µm)	Karbon	Sıcaklık (°C)	Güç (W)	Kuvvet (N)	CODAS Skoru
#1	**36°/38°**	50.0	0.010	0.095	0.692	169.9	581.0	41.4	**6.14**
#2	**30°/32°**	50.0	0.010	0.082	0.692	157.7	578.4	51.6	**6.09**
#3	**30°/32°**	50.0	0.010	0.082	0.692	157.7	578.5	51.6	**6.09**
#4	**30°/32°**	50.0	0.025	0.087	0.653	157.7	590.9	51.6	**6.00**
#5	**36°/38°**	50.0	0.025	0.107	0.652	169.9	591.7	41.4	**5.81**

Endüstriyel Değerlendirme & Sonuç: CODAS algoritmasının en ideal ilk 5 çözümü incelendiğinde, en optimum dengenin 30°/32° ve 36°/38° değişken helis açılı takımlarda, 50 m/dk kesme hızı ve 0.010 - 0.025 mm/dev düşük ilerleme aralığında yoğunlaştığı doğrulanmıştır. Değişken helis açısı, frezelemedeki tırlama (chatter) titreşimlerini bastırarak yüzey kalitesini maksimize ederken düşük ilerleme kesme kuvveti ve sıcaklığı minimize etmektedir.

9. Genel Sonuçlar ve Kapsamlı Değerlendirme

Bu çalışma kapsamında, DIN 1.2738 plastik kalıp çeliğinin sürdürülebilir frezelenmesi sürecinde elde edilen deneysel veriler, literatürdeki en ileri yapay zeka (AI) algoritmaları kullanılarak modellenmiş ve çok amaçlı bir optimizasyon çerçevesine oturtulmuştur. Toplam 7 farklı makine öğrenmesi algoritması (MLR, RF, SVR, GPR, XGBoost, K-NN, LightGBM) kullanılarak yüzey pürüzlülüğü, karbon emisyonu, kesme sıcaklığı, kesme gücü ve kesme kuvveti gibi 5 kritik endüstriyel kalite karakteristiği için toplam 35 çapraz eşleşmeli model-hedef denemesi gerçekleştirilmiştir. K-Katlı Çapraz Doğrulama (K-Fold CV) ve holdout test kümeleriyle desteklenen bu kıyaslama süreci, modellerin dış verilere karşı üstün genelleme yeteneğini açıkça kanıtlamıştır.

Modellerin performans farklılıklarının rastgele olmadığını ispatlamak amacıyla Friedman İstatistiksel Anlamlılık Testi kullanılmış ve istatistiksel güvence sağlanmıştır. Ek olarak, makine öğrenmesi modellerinin 'kara kutu' (black-box) dezavantajını ortadan kaldırmak için, oyun teorisi temelli SHAP (Shapley Additive exPlanations) algoritması sisteme entegre edilmiştir. SHAP analizinden elde edilen özellik önem (feature importance) bulguları, ilerleme miktarının (f) yüzey pürüzlülüğü üzerindeki dominant etkisini şeffaf bir biçimde matematiksel olarak kanıtlayarak, veri bilimi sonuçlarının geleneksel talaşlı imalat teorisiyle (kinematik ve termodinamik beklentilerle) tam uyum içinde olduğunu doğrulamıştır.

Çalışmanın nihai aşamasında, talaşlı imalatta birbirine zıt çalışan çoklu hedeflerin (örneğin; işleme süresini kısaltırken pürüzlülüğü artırma) ortak bir çözümde buluşturulması hedeflenmiştir. Bu doğrultuda en başarılı regresyon algoritmaları vekil fonksiyon (surrogate function) olarak kullanılmış ve evrimsel NSGA-II algoritmasıyla entegre çalıştırılarak Pareto-Optimal sınır denge kümesi türetilmiştir. Elde edilen bu alternatif çözümler, son olarak CRITIC-CODAS çok kriterli karar verme (MCDM) hibrit yapısı ile sıralanmış ve üretime doğrudan aktarılabilecek en verimli endüstriyel parametre tavsiyeleri bulunmuştur. Sonuç olarak bu entegre dijital zeka sistemi, salt deneme-yanılma yaklaşımını ortadan kaldırarak üretim hatlarında maliyet, zaman ve enerji tasarrufu sağlamak için güvenilir ve bilimsel bir çerçeve sunmaktadır.